

## Binary Classifiers for Nucleotide Sequencing Data

DeepBind (2015, Nature biotechnology)

Presenter

Gwangho Lee

Computer Science Engineering, Pusan National University

Machine Learning & Bioinformatics Lab

## Contents

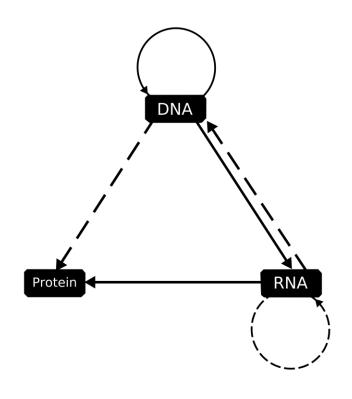
- 1. 실습 연구 소개
- 2. 실습 및 예시 코드
- 3. 후속 연구 소개

## 1. 실습 연구 소개 – DeepBind (2015, Nature biotechnology)

Predicting the sequence specificities of DNA- and RNA-binding proteins by deep learning Published paper: <a href="https://www.nature.com/articles/nbt.3300">https://www.nature.com/articles/nbt.3300</a>

## 분자생물학의 중심 원리 (Central Dogma of Molecular Biology)

단백질로 만들어진 (유전)정보는 다른 단백질이나 핵산으로 전달될 수 없다



분자생물학의 중심 원리. 유전 정보가 전달되는 과정

#### ━━ 일반적인 전이 과정

- 1. 세포내 유전정보 DNA가 스스로를 복제
- 2. DNA가 RNA를 생성하는 전사(transcription)
- 3. RNA에서 단백질(protein)을 생성하는 번역(translation)

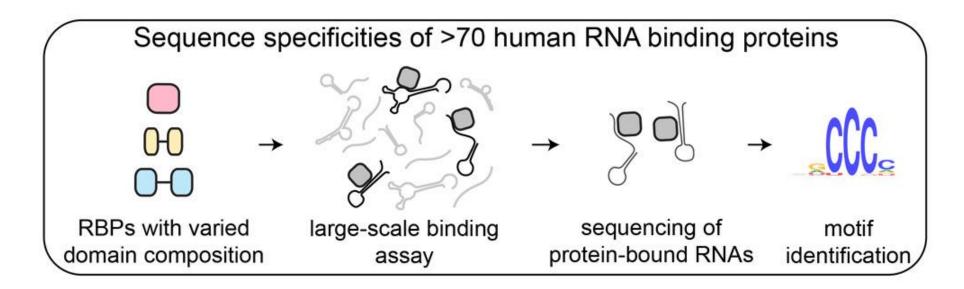
#### --▶ 특수한 전이 과정

- 추정, 연구단계에서 논의되는 전이 현상
- 예를 들어 RNA에서 DNA를 생성하는 과정

#### 그 외, 센트럴 도그마에 위배되는 사례

- 역전사를 통한 유전정보 전달되는 예 <u>레트로바이러스</u>
- 유전정보 없이 형질 전달되는 예 프리온
- <u>후성유전학 일란성 쌍둥이</u>

## **RNA Binding Proteins (RBPs)**



"Knowing the sequence specificities of DNA- and RNA-binding proteins is essential for developing models of the regulatory processes in biological systems and for identifying causal disease variants."

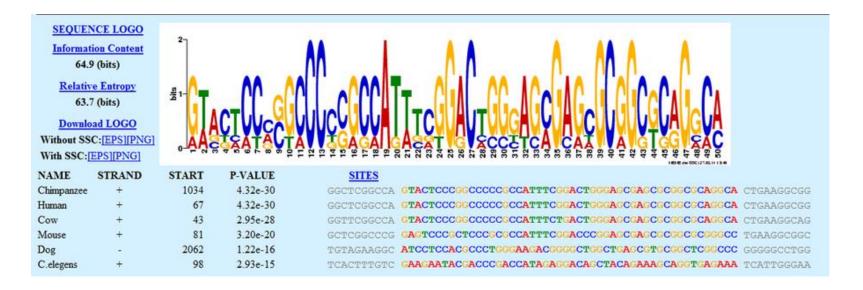
DNA- 또는 RNA-결합 단백질들에 대한 서열 특이성을 밝혀내는 것은 생물학적 시스템들이나 질병의 인과관계를 규명하는 것에 아주 핵심적인 역할을 한다

✔ 연구의 목표

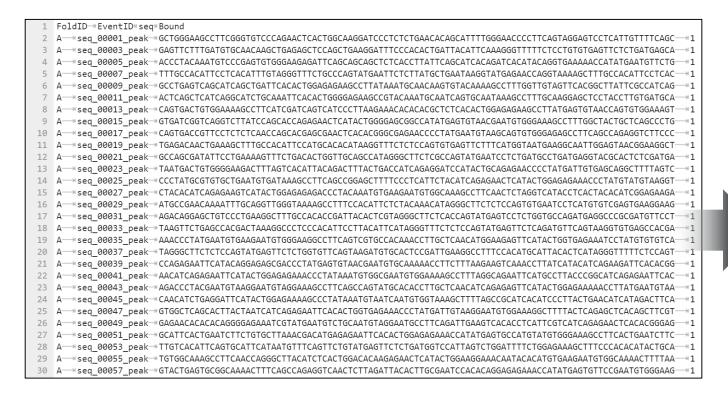
대부분의 DNA- and RNA-binding proteins 연구와 유사하게 해당 단백질에 대한 motif를 찾는 것

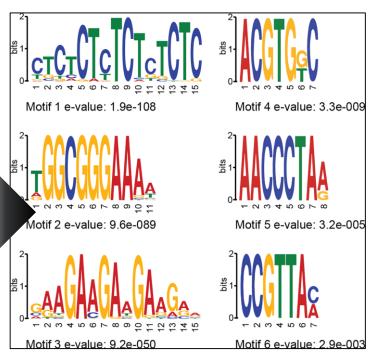
✔ Motif(모티프)란 무엇인가?

유전학에서 뉴클레오타이드 또는 아미노산 서열 패턴을 의미, 이를 sequence motif라고 함



- ✔ 연구의 동기
- Q. 부분 서열 탐색 알고리즘으로 패턴 찾으면 될 일이 아닌가? 🤔
- A. 전통적인 연구 방향성이 맞음, 하지만 최근의 머신러닝 & 딥 러닝 기술의 발전을 통해 새로운 접근을 시도하는 중





DeepBind (2015) 모델 연구에 대한 개요 (그림1)

- 1. High-throughput experiments 유전체, 분자생물학 실험 데이터 수집 및 가공 단계
- 2. Massively parallel deep learning 실험 데이터를 사용한 머신러닝, 딥러닝 모델링 단계 (학습)
- 3. Community needs 학습된 모델을 바탕으로 유의미한 분석을 수행하는 단계

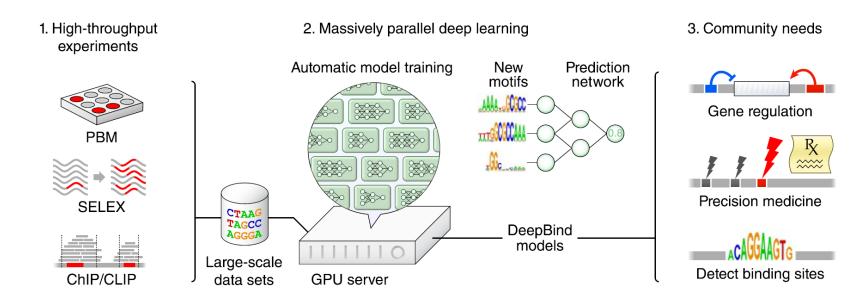


그림1. DeepBind's input data, training procedure and applications

DeepBind (2015) 모델 연구에 대한 개요 (그림1)

- 1. High-throughput experiments 유전체, 분자생물학 실험 데이터 수집 및 가공 단계
- 2. Massively parallel deep learning 실험 데이터를 사용한 머신러닝, 딥러닝 모델링 단계 (학습)
- 3. Community needs 학습된 모델을 바탕으로 유의미한 분석을 수행하는 단계

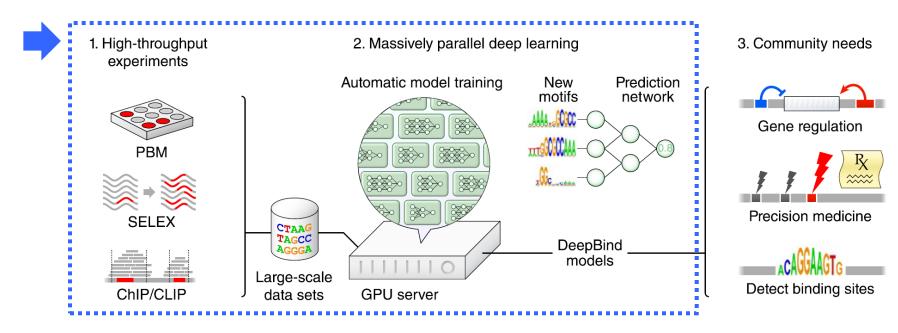
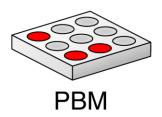


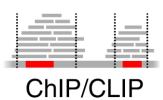
그림1. DeepBind's input data, training procedure and applications

## High-throughput experiments, 용어 및 내용 정리

1. High-throughput experiments







#### High-throughput

- 일반적으로 1회 정도 할 수 있던 일을 100회 이상 대용량고효율로 처리하는 것을 의미
- High-throughput platform을 갖추다 ~ 라는 표현으로 많이 사용

#### Sequencing

- 시퀀싱(sequencing)이란 DNA 서열을 분석하기 위해 생화학적 방법으로 모든 세포의 DNA 사슬을 구성하는 염기(A, C, G, T)가 결합된 순서를 분석하는 기술

#### NGS

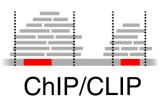
- Next Generation Sequencing 의 약자, 유전체의 염기서열을 고속으로 분석하는 기법
- 하나의 유전체를 수많은 조각으로 분해하여 각 조각을 동시에 읽은 후 전산 기술(ex. alignment algorithm)으로 조합하여 유전체 정보를 해독하는 방법

## High-throughput experiments, 용어 및 내용 정리

1. High-throughput experiments







#### **PBM**

- Protein (Binding) Microarray 실험의 약자 (high-throughput 실험)
- 특정 리간드(ligand)에 결합하는 수용체(receptor)를 검출하는데 사용 가능

#### SELEX

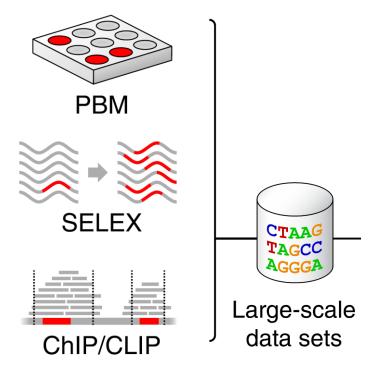
- 특정 수용체(ex. Protein)에 결합하는 인공적인 DNA/RNA 서열 생성 실험

#### ChIP-seq

- 특정 단백질이 결합(binding)하는 DNA서열을 NGS로 시퀀싱
- 유전체 전체에서 결합 가능한 motif 를 탐색하기위해 사용

## **High-throughput Sequencing Data**

1. High-throughput experiments



#### Large-scale data sets

- 표적 단백질에 결합한 DNA/RNA 서열 정보를 포함한 텍스트 파일들

```
FoldID-EventIDesegeBound
9 A---seq 00015 peak--sGTGATCGGTCAGGTCTTATCCAGCACCAGAGAACTCATACTGGGGAGCGGCCATATGAGTGTAACGAATGTGGGAAAGCCTTTGGCTACTGCTCAGCCCTG-
                                                     →seq 00001 peak → GCTGGGAAGCCTTCGGGTGTCCCAGAAC
11 A──seq 00019 peak──TGAGACAACTGAAAGCTTTGCCACATTCCATGCACACAT
12 A—*seq_00021_peak—*GCCAGCGATATTCCTGAAAAGTTTCTGACACTGGTTGCA

→ seq 00003 peak → GAGTTCTTTGATGTGCAACAAGCTGAGA
13 A—*seq 00023 peak—*TAATGACTGTGGGGAAGACTTTAGTCACATTACAGACT
14 A─wseq_00025_peak → CCCTATGCGTGTGCTGAATGTGATAAAGCCTTCAGCCGG
                                                      ♥seq_00005_peak→ACCCTACAAATGTCCCGAGTGTGGGAAGA
15 A─mseq_00027_peak → CTACACATCAGAGAAGTCATACTGGAGAGAGACCCTACA
16 A─mseq 00029 peak → ATGCCGAACAAAATTTGCAGGTTGGGTAAAAGCCTTTCG

→ seq 00007 peak
→ TTTGCCACATTCCTCACATTTGTAGGGT

17 A-seq 00031 peak-AGACAGGAGCTGTCCCTGAAGGCTTTGCCACACCGATT
18 A─mseq 00033 peak → TAAGTTCTGAGCCACGACTAAAGGCCCTCCCACATTCCT
19 A-seq_00035_peak-AAACCCTATGAATGTGAAGAATGTGGGAAGGCCTTCAG

→ seq 00009 peak → GCCTGAGTCAGCATCAGCTGATTCACAC

20 A seq_00037_peak TAGGGCTTCTCTCCAGTATGAGTTCTCTGGTGTTCAGTA

→ seq 00011 peak → ACTCAGCTCATCAGGCATCTGCAAATTCA

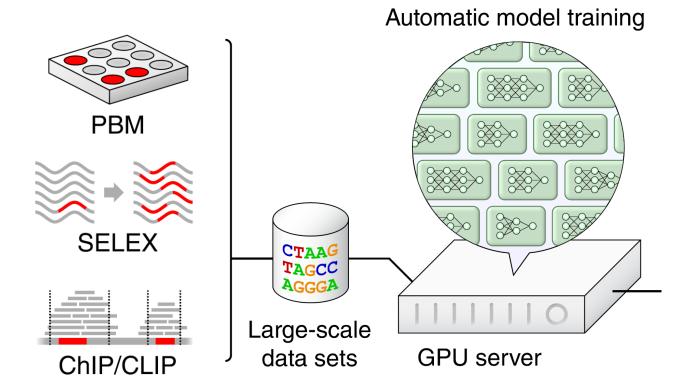
23 A-seq_00043_peak-AGACCCTACGAATGTAAGGAATGTAGGAAAGCCTTCAGG
                                                      seq 00013 peak→CAGTGACTGTGGAAAAGCCTTCATCGAT
24 A seq 00045 peak CAACATCTGAGGATTCATACTGGAGAAAAGCCCTATAAA
                                                      seg 00015 peak→GTGATCGGTCAGGTCTTATCCAGCACCA
25 A—*seq 00047 peak—*GTGGCTCAGCACTTACTAATCATCAGAGAATTCACACTG
26 A seq 00049 peak GAGAACACACACAGGGGAGAAATCGTATGAATGTCTGCA
27 A-seq 00051 peak-GCATTCACTGAATCTTCTGTGCTTAAACGACATGAGAG
                                                      seq 00017 peak→CAGTGACCGTTCCTCTCAACCAGCAC
28 A-seq_00053_peak-TTGTCACATTCAGTGCATTCATAATGTTTCAGTTCTGTA
29 A─wseq 00055 peak → TGTGGCAAAGCCTTCAACCAGGGCTTACATCTCACTGG
                                                      seq 00019 peak→TGAGACAACTGAAAGCTTTGCCACATTC
30 A─wseq 00057 peak-WGTACTGAGTGCGGCAAAACTTTCAGCCAGAGGTCAACTG
                                                      seq 00021 peak→GCCAGCGATATTCCTGAAAAGTTTCTGA

★seq 00023 peak

▼TAATGACTGTGGGGAAGACTTTAGTCAC
```

#### How to find motifs? 😕

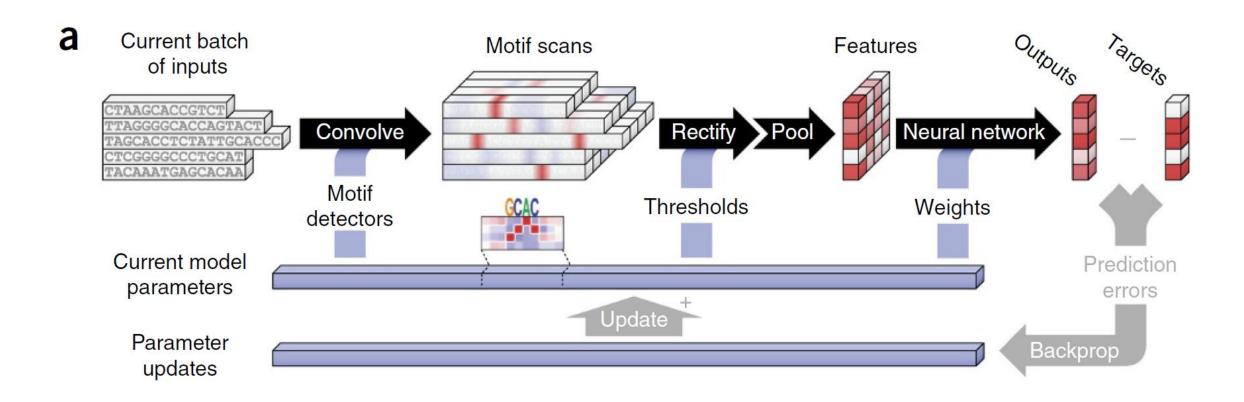
1. High-throughput experiments

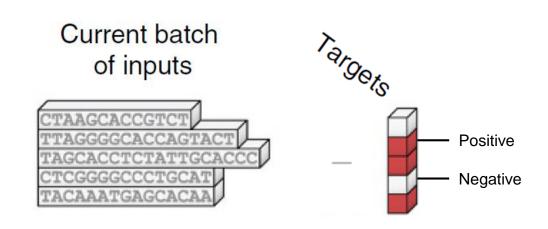


#### Automatic model training

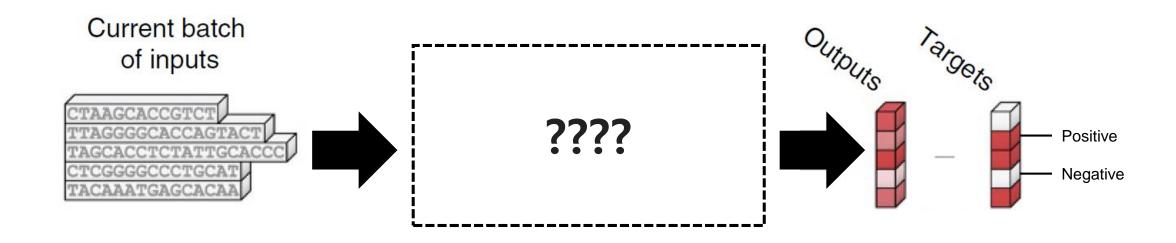
- 표적 단백질에 결합한 DNA/RNA 서열들을 학습시킨다???



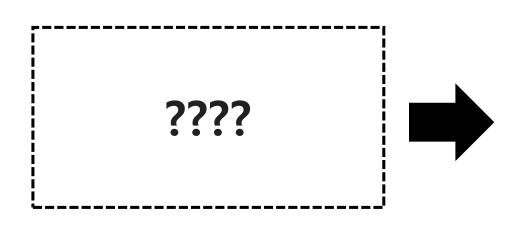




① 실험 결과, 발생한 서열들은 Positive class, 그렇지 못한 서열들 (없으면 무작위 서열)은 Negative class로 지정

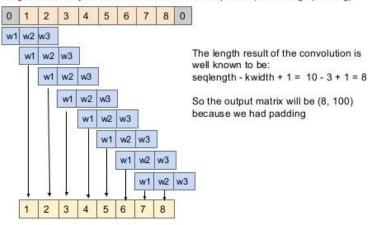


- ① 실험 결과, 발생한 서열들은 Positive class, 그렇지 못한 서열들 (없으면 무작위 서열)은 Negative class로 지정
- ② 만약 어떤 방법(혹은 모델)이 이 두가지 class들을 분류할 수 있다면 해당 모델은 입력 서열에서 유의미한 패턴 정보를 파악한 것

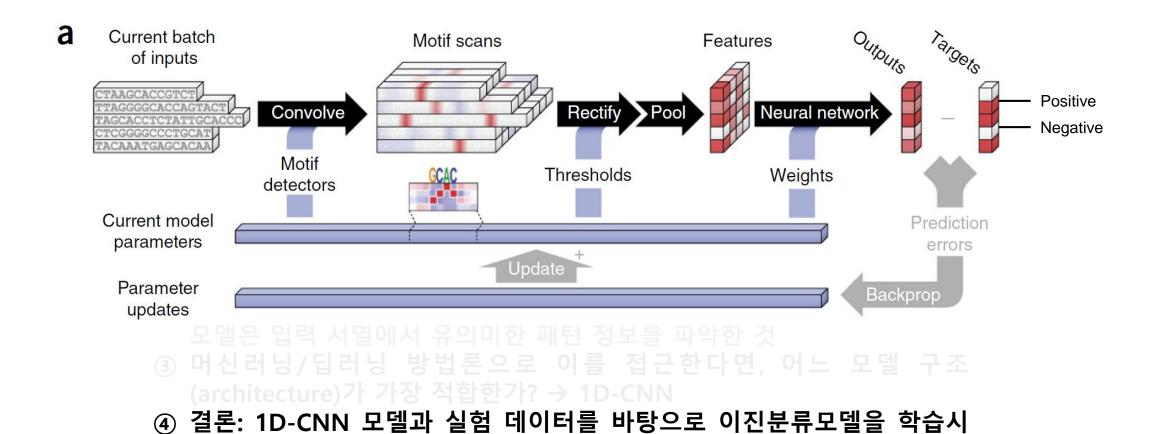


#### **1D Convolutions**

When we add zero padding, we normally do so on both sides of the sequence (as in image padding)

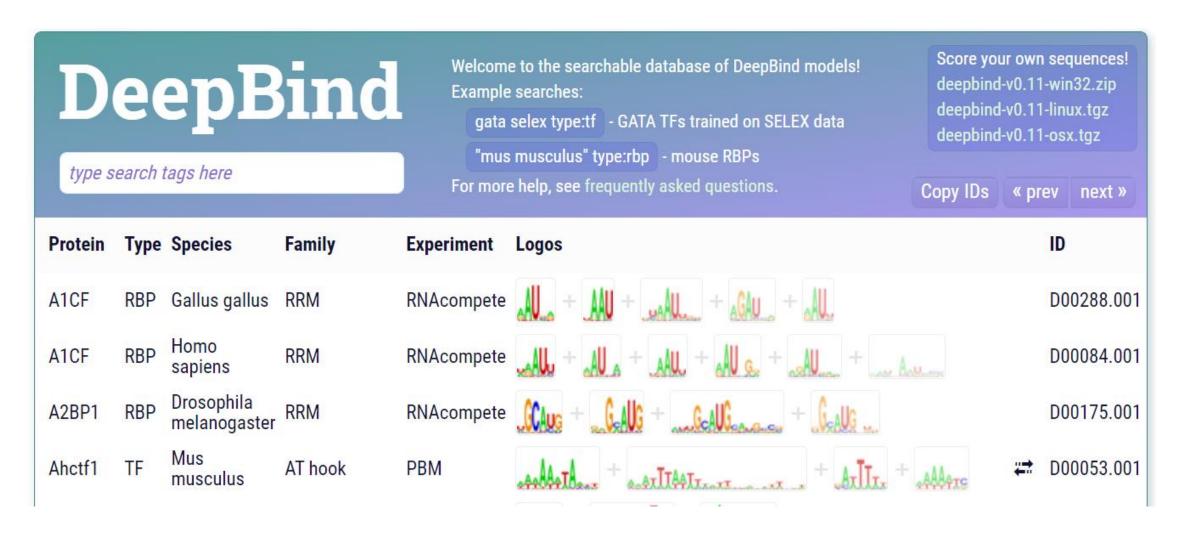


- ① 실험 결과, 발생한 서열들은 Positive class, 그렇지 못한 서열들 (없으면
- ② 만약 어떤 방법(혹은 모델)이 이 두가지 class들을 분류할 수 있다면 해당 모델은 입력 서열에서 유의미한 패턴 정보를 파악한 것
- ③ 머신러닝/딥러닝 방법론으로 이를 접근한다면, 어느 모델 구조 (architecture)가 가장 적합한가? → 1D-CNN



키면 CNN 구조의 filter 정보로 motif를 추론할 수 있다

## http://tools.genes.toronto.edu/deepbind/



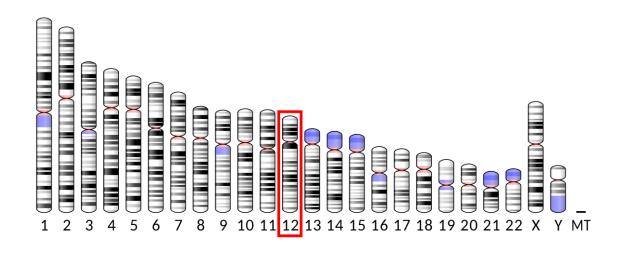
## 2. 실습 및 예시 코드 – ML/DL for sequencing data

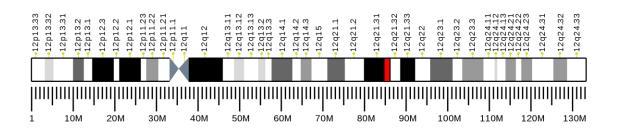
실습 목표 확인, 데이터 준비, etc ···

#### 실습 과제 목표

- 1. 이진 분류 모델 학습을 위한 sequencing 데이터 준비하기
- 2. Sequencing 데이터를 다양한 머신러닝 모델에 사용하기
- 3. 이진 분류 모델의 학습에 대한 올바른 평가 수행하기
- ※ Motif 찾는 사후 분석은 제외

#### Download raw data





## Alx<sub>1</sub>

**ALX homeobox protein 1** is a <u>protein</u> that in humans is encoded by the *ALX1* <u>gene</u>.

ID: **D00289.002** 

Type: **TF**

Species: Mus musculusFamily: Homeodomain

• Experiment: **SELEX** 

Model: deepbind 0.1

Cite: **PMID 23332764** 

Wiki: <a href="https://en.wikipedia.org/wiki/ALX1">https://en.wikipedia.org/wiki/ALX1</a>

DeepBind info: (link)

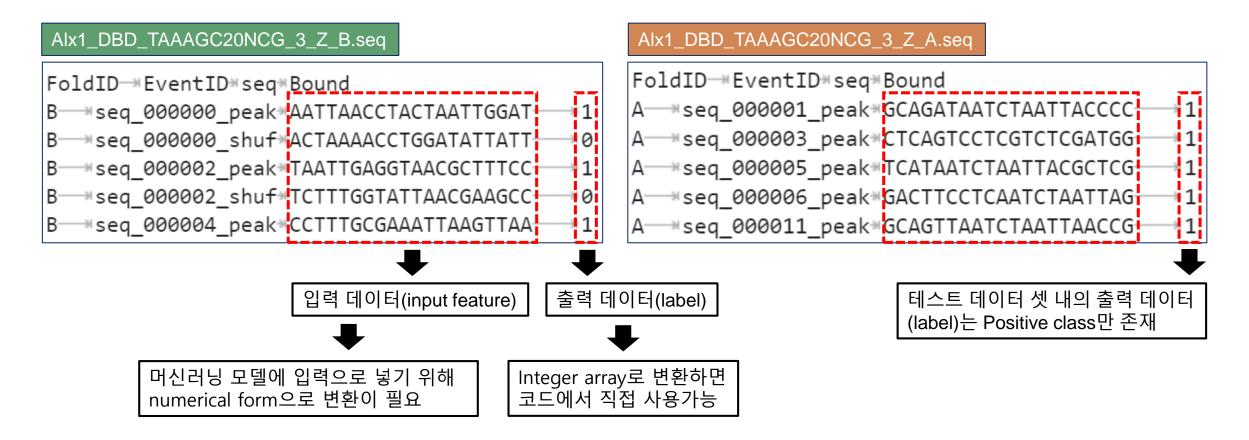
## Sequence Dataset for Binary Classifier (Source: DeepBind)

Download type-A (<u>link</u>)

Download type-B (<u>link</u>)

#### About the raw data sequences

- Alx1\_DBD\_TAAAGC20NCG\_3\_Z\_B.seq (학습 및 평가용 데이터)
- Alx1\_DBD\_TAAAGC20NCG\_3\_Z\_A.seq (테스트용 데이터)



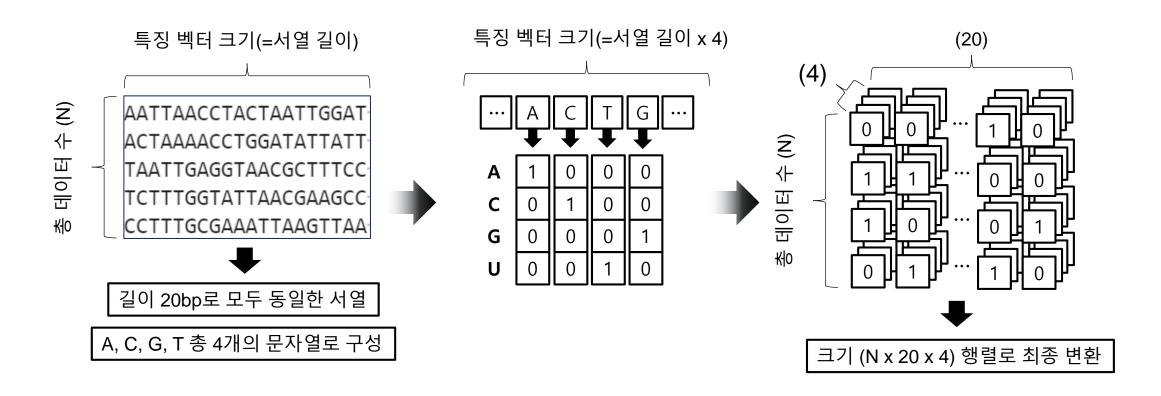
#### Load the downloaded raw data

- Alx1\_DBD\_TAAAGC20NCG\_3\_Z\_B.seq (학습 및 평가용 데이터)
- Alx1\_DBD\_TAAAGC20NCG\_3\_Z\_A.seq (테스트용 데이터)

```
from collections import defaultdict
import numpy as np
def raw seq parser(path):
   f = open(path, "r")
   seqs = []
   seq lens = []
   labels = []
   flines = f.readlines()
   cols = None
   for i, line in enumerate(flines):
       if not i :
           cols = line.replace("\n","").split("\t")
       else:
           fold_id, event_id, seq, bound = line.replace("\n","").split("\t")
           seqs.append(seq)
           labels.append(int(bound))
           seq lens.append(len(seq))
   num pos = sum(labels)
   num neg = len(labels) - num pos
   print("Load {} finish ({} lines, #positive: {}, #negative: {})".format(path, len(labels), num_pos, num_n
   print("- sequence sizes : {}".format(set(seq_lens)))
   return segs, labels
                                                                                   Load Alx1 DBD TAAAGC20NCG 3 Z B.seq finish (255508 lines, #positive: 127754, #negative: 127754)
                                                                                   - sequence sizes : {20}
# path of raw data
                                                                                  Load Alx1 DBD TAAAGC20NCG 3 Z A.seq finish (128012 lines, #positive: 128012, #negative: 0)
TRAIN RAW = "Alx1 DBD TAAAGC20NCG 3 Z B.seq"
TEST RAW = "Alx1 DBD TAAAGC20NCG 3 Z A.seq"
                                                                                   - sequence sizes : {20}
train_seqs, train_labels = raw_seq_parser(TRAIN_RAW)
test segs, test labels = raw seg parser(TEST RAW)
```

## Sequence Encoding (one-hot encoding)

- 별도의 변환 없이, 데이터 그 자체를 표현할 수 있는 간단한 방법
- 보통 classification 데이터의 label 변환에 자주 사용된다 (ex. 4 classes, class-4 → [0,0,0,1])
- 생물정보학 분야에서 염기서열을 표현할 때 많이 사용되나, 길이가 다른 서열들을 표현하기엔 어려움



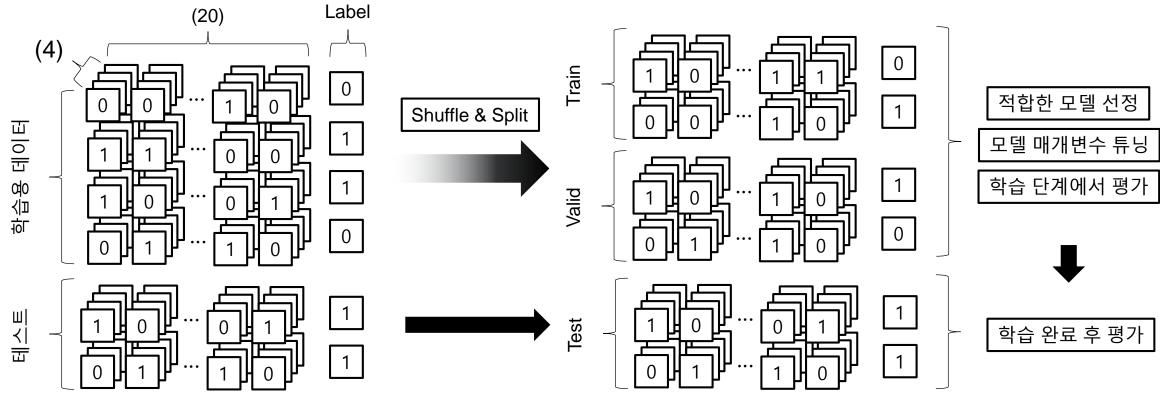
## Sequence Encoding (one-hot encoding)

```
def onehot_encoder(seqs, letters="ACGT"):
    enc = defaultdict(lambda: np.array([1/len(letters)]*len(letters))) # default. [0.25,0.25,0.25,0.25]
   for i,l in enumerate(letters):
       f = np.zeros(len(letters))
       f[i] = 1
       enc[1] = f
   onehot features = []
   for seq in seqs:
       feature = []
       for c in seq.upper():
           feature.append(enc[c])
        onehot features.append(feature)
    onehot features = np.array(onehot features)
    print("One-hot encoding finished, with feature shape {}".format(onehot features.shape))
    return onehot features
X = onehot_encoder(train_seqs)
test x = onehot encoder(test seqs)
```

One-hot encoding finished, with feature shape (255508, 20, 4) One-hot encoding finished, with feature shape (128012, 20, 4)

#### Split Training & Validation datasets

- 테스트 데이터 셋은 모델 학습 후 최종 평가 시 사용
- 학습 데이터를 학습용(training) 및 평가용(validation)으로 분리하여 overfitting 방지 및 hyper-parameter tuning에 사용
- Scikit-learn 패키지의 train\_test\_split (ref-link)으로 쉽게 코딩 가능



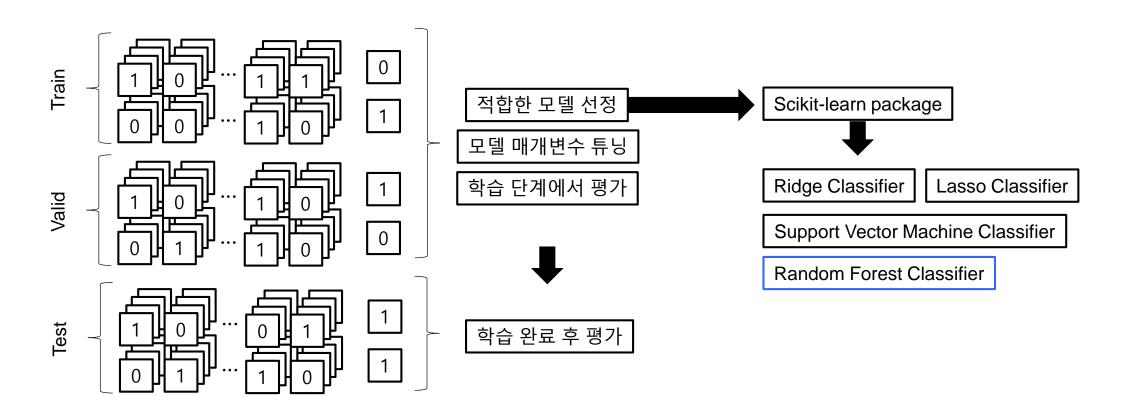
#### Split Training & Validation datasets

- 테스트 데이터 셋은 모델 학습 후 최종 평가 시 사용
- 학습 데이터를 학습용(training) 및 평가용(validation)으로 분리하여 overfitting 방지 및 hyper-parameter tuning에 사용
- Scikit-learn 패키지의 train\_test\_split (ref-link)으로 쉽게 코딩 가능

```
Train set | x: (171190, 20, 4), y: (171190,)
Valid set | x: (84318, 20, 4), y: (84318,)
```

## **Binary Classifier**

• 기본적인 binary classifier 학습 준비 과정 및 평가 단계를 모두 숙지하기 위해 해당 실습에서는 기본적인 머신러닝 분류 모델만 사용 (ref. scikit-learn package)



#### Initialize a Random Forest Classifier

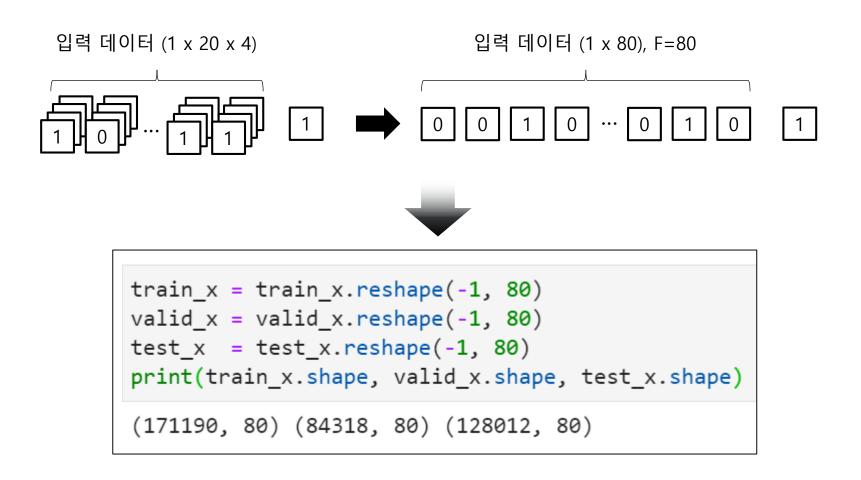
• 정형 데이터에서 대체로 robust하게 동작하는 Random Forest 분류 모델을 사용



```
RandomForestClassifier(bootstrap=True, ccp_alpha=0.0, class_weight='balanced', criterion='gini', max_depth=10, max_features='auto', max_leaf_nodes=None, max_samples=None, min_impurity_decrease=0.0, min_impurity_split=None, min_samples_leaf=1, min_samples_split=2, min_weight_fraction_leaf=0.0, n_estimators=200, n_jobs=None, oob_score=False, random_state=None, verbose=0, warm_start=False)
```

#### Train the Random Forest Classifier

Random Forest 모델 입력으로 사용하기 위해 입력 데이터 행렬 형식 변환 (N x F) where F = #features



#### Train the Random Forest Classifier

- Random Forest 모델 입력으로 사용하기 위해 입력 데이터 행렬 형식 변환 (N x F) where F = #features
- 데이터 수가 많아서 일부만 사용



```
train_x = train_x.reshape(-1, 80)[:5000]
valid_x = valid_x.reshape(-1, 80)[:1000]
test_x = test_x.reshape(-1, 80)[:100]

train_y = np.array(train_y[:5000])
valid_y = np.array(valid_y[:1000])
test_y = np.array(test_y[:100])

print(train_x.shape, valid_x.shape, test_x.shape)
print(train_y.shape, valid_y.shape, test_y.shape)

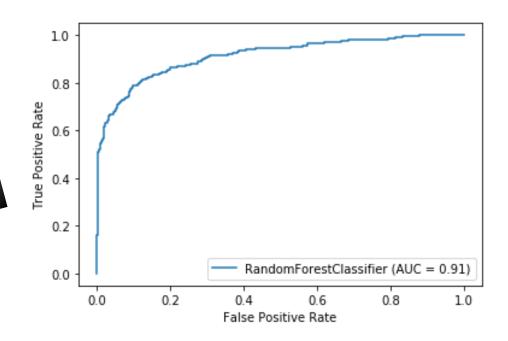
(5000, 80) (1000, 80) (100, 80)
(5000,) (1000,) (100,)
```



#### **Model Evaluation**

- 학습된 이진 분류 모델의 성능을 평가
- Receiver operating characteristic (ROC) Area Under the Curve (AUC) 값이 대체로 많이 사용됨
- ROC-AUC, AUC로 불리는 이 값은 0 ~ 1 사이 값을 가지며 1에 가까울수록 좋다
- 참고자료 : <a href="https://en.wikipedia.org/wiki/Receiver operating characteristic">https://en.wikipedia.org/wiki/Receiver operating characteristic</a>
- Scikit-learn 패키지를 사용하면 plot 까지 바로 제공하는 함수를 사용 가능

```
import matplotlib.pyplot as plt
from sklearn import datasets, metrics, model_selection
metrics.plot_roc_curve(model, valid_x, valid_y)
plt.show()
```



#### **Model Evaluation**

- Scikit-learn / classification\_report / 학습된 (이진) 분류 모델의 성능을 종합적으로 평가
- Positive class 뿐인 테스트 데이터 셋을 평가할 때 ROC-AUC를 사용할 수 없음 (직접 실행해보는 것을 추천)
- Precision, Recall, F1-score 같은 기본적인 분류 모델 평가 수치를 간편하게 출력해주는 함수 (classification\_report)

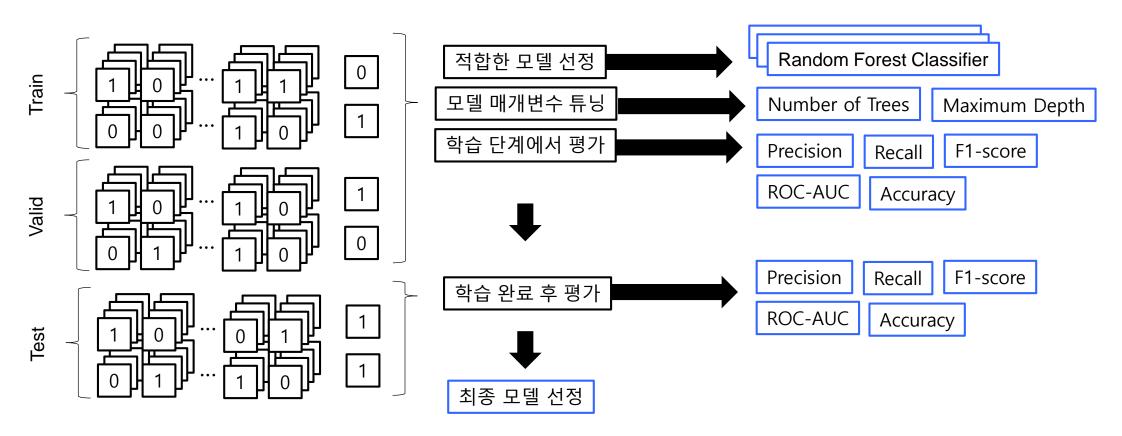
```
valid_pred_y = model.predict(valid_x)
print(metrics.classification_report(valid_y, valid_pred_y))
```



	precision	recall	f1-score	support
0	0.82	0.87	0.84	2567
1	0.85	0.80	0.83	2433
accuracy			0.84	5000
macro avg	0.84	0.84	0.84	5000
weighted avg	0.84	0.84	0.84	5000

#### **Model Selection**

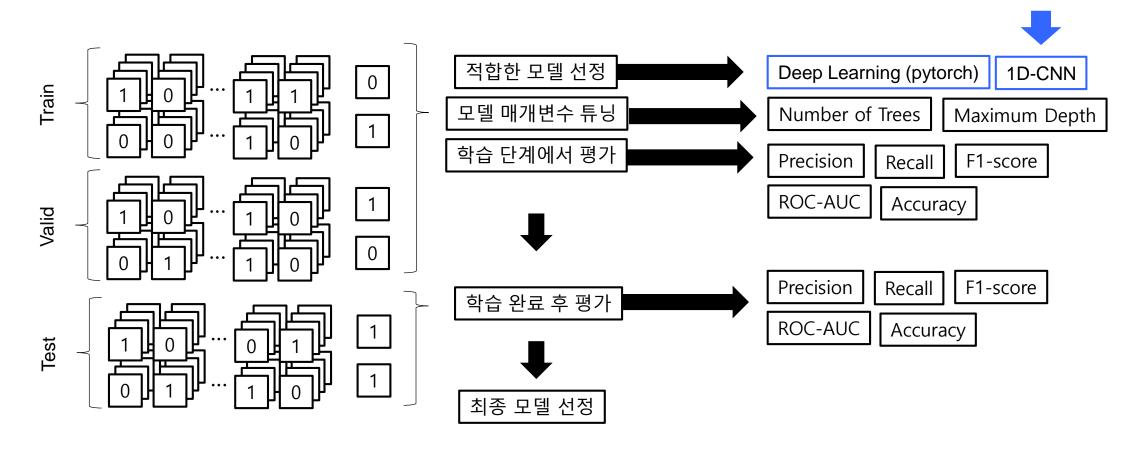
- 다양한 머신러닝 모델을 평가 및 비교
- 각 모델의 매개변수를 변경해보며 성능을 평가 및 비교
- 학습 된 모델을 테스트 데이터로 성능 평가 및 비교



## 3. 후속 연구 소개 – Deep Learning & Motif analysis

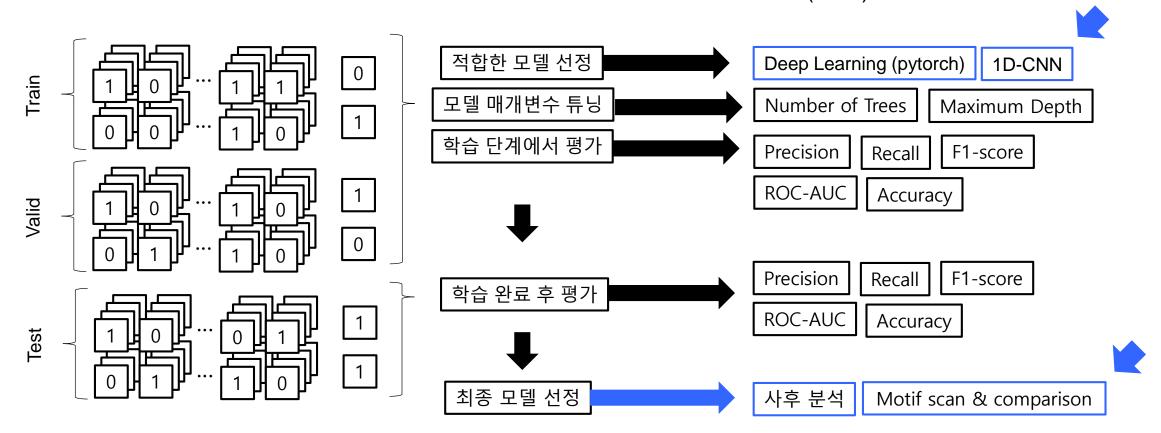
## 1D-CNN (Convolutional Neural Network)

- 모델 평가 및 선별 방식은 크게 변하지 않음
- 학습 모델을 딥 러닝 모델 사용



## 1D-CNN (Convolutional Neural Network) + Motif scan

- 모델 평가 및 선별 방식은 크게 변하지 않음
- 학습 모델을 딥 러닝 모델 사용
- 1D-Convolutional Neural Network를 사용하여 motif 를 찾는 것 까지 진행 (예정)



# Thank you Q & A



DeepBind Example full script (link)